MEDLABEL REVIEW

药品说明书版本比对与变更审核系统

V1.0

软件设计说明书

著作权人：待申请人填写

对应代码版本：98e406f

文档状态：技术内容已编制，申请信息待确认

本文所示药品、说明书及审核记录均为软件演示资料。

内容索引

1. 软件概述与设计目标

2. 运行环境与技术组成

3. 总体结构与模块划分

4. 数据库与附件设计

5. 文件导入与原始资料保存

6. 章节识别与人工校正

7. 差异计算与关注标记

8. 审核状态与事务一致性

9. 界面与交互设计

10. HTTP 接口设计

11. 报告设计

12. 配置、访问保护与恢复

13. 验证与维护

文档项目	内容
软件全称	药品说明书版本比对与变更审核系统
软件版本	V1.0
英文项目名	MedLabel Review
对应程序版本	Git 提交 98e406f；程序内部版本号 1.0.0
著作权人	待申请人填写
文档用途	说明软件结构、数据组织、处理流程及实现方法

1. 软件概述与设计目标

本软件围绕药品说明书资料的版本管理与人工审核，建立“药品档案—说明书版本—章节差异—审核意见—导出报告”的关联关系。使用者将同一药品的新旧说明书归入同一档案，检查提取文本与章节结构，创建比对后逐项确认或忽略差异，保留操作过程。

系统的主要设计目标为：保留可回查的原始资料；按说明书章节定位变化；突出数字、单位及重点章节变化；将文本比对与人工审核衔接；提供便于查阅、整理及程序处理的报告。软件采用确定性规则和文本差异算法，不通过生成式模型推测原文含义。

V1.0 面向单机、单个可信操作者使用。药学审核结论由使用者负责，程序输出的是文本变化和记录状态，不构成药品安全性、有效性或监管审批结论。本版本未实现 OCR、账户认证、多人权限隔离、电子签名或医院信息系统对接。

2. 运行环境与技术组成

程序使用 Python 3.11 及以上版本运行，浏览器访问本机 HTTP 服务。已验证环境包含 Python 3.11、Python 3.12 和 Chromium。代码提供 Windows PowerShell 与 macOS/Linux Shell 启动脚本，具体安装使用说明见配套用户操作说明书。

组成	实现方式	作用
服务端	Python、FastAPI、Uvicorn	HTTP 接口、业务验证、静态资源服务
数据保存	SQLite、Python sqlite3	档案、版本、比对、审核及操作记录
文档解析	pypdf、python-docx、标准编码解码	PDF、DOCX、TXT 文字提取
差异算法	Python difflib.SequenceMatcher	章节内字符级差异片段
用户界面	HTML、CSS、原生 JavaScript	浏览器交互、差异展示、表单与筛选
报告	HTML、CSV、JSON	阅读打印、表格整理、结构化交换

前端由同一服务端提供，不要求 Node.js 构建工具。依赖安装完成后，本地文档处理不需要外部网络、大模型密钥或第三方数据库服务。运行依赖见 requirements.txt，验证环境完整版本见 requirements-lock.txt。

3. 总体结构与模块划分

系统采用浏览器界面、HTTP 业务接口、文档处理与比对模块、本地存储四部分结构。浏览器通过 fetch 请求业务接口；接口先校验输入，再调用解析、比对或报告模块；数据库保存结构化记录，上传文件保存在独立目录。处理结果以 JSON 返回界面或以附件形式下载。

模块	对应文件	主要职责
启动模块	run.py	解析监听地址、端口、数据目录并启动服务
应用接口模块	app/main.py	应用初始化、输入模型、业务路由、请求校验
数据模块	app/database.py	建表、连接、事务及日志写入
文档模块	app/documents.py	文件提取、标题规范化、章节划分、人工校正校验
比对模块	app/comparison.py	章节匹配、变化分类、差异片段、关注标记
报告模块	app/reports.py	来源信息、审核状态及差异的多格式输出
示例模块	app/demo.py	明确标注的模拟药品和说明书文本
界面模块	app/static/	工作台、药品版本、比对审核、操作记录

同一说明书版本可参与多个比对，每个比对记录固定一组旧版、新版及生成时的差异。审核记录附属于具体差异；再次建立比对不会在后台重算或覆盖原有任务。

4. 数据库与附件设计

数据库文件名为 medlabel.sqlite3，原始附件保存在同一数据目录下的 uploads 子目录。数据库包含六张表。业务对象的 id 使用 INTEGER PRIMARY KEY；日期时间以 TEXT 保存，版本日期采用 YYYY-MM-DD，操作时间采用带时区的 UTC ISO 格式。JSON 内容存于 TEXT 字段，由应用进行序列化和解析。

4.1 药品档案表 drugs

字段	类型	含义与约束
id	INTEGER	主键
name	TEXT	药品名称，非空
manufacturer	TEXT	厂家，非空，默认空串
specification	TEXT	规格，非空，默认空串
approval_number	TEXT	批准文号，非空，默认空串
notes	TEXT	备注，非空，默认空串
created_at	TEXT	创建时间，非空

药品档案用于归集资料，不向外部监管数据库核验药品名称或批准文号。

4.2 说明书版本表 versions

字段	类型	含义与约束
id	INTEGER	主键
drug_id	INTEGER	所属药品，外键指向 drugs.id
label	TEXT	版本名称
version_date	TEXT	版本日期
source	TEXT	资料来源描述
filename	TEXT	清理路径后的原始文件名
sha256	TEXT	原始文件字节的 SHA-256
storage_name	TEXT	随机生成的内部附件名
text	TEXT	提取原文
sections	TEXT	章节列表 JSON
warnings	TEXT	提取或人工校正提示 JSON，默认空列表
created_at	TEXT	导入时间

版本表以上业务字段均设置 NOT NULL。每个章节包括 key、title、text、start_line、end_line。行号指向提取文本，不能直接换算为 PDF 页面坐标。接口对外不返回 storage_name。

4.3 比对表 comparisons

字段	类型	含义与约束
id	INTEGER	主键
drug_id	INTEGER	药品外键
old_version_id	INTEGER	旧版本外键，指向 versions.id
new_version_id	INTEGER	新版本外键，指向 versions.id
unchanged_sections	INTEGER	正文未变化的章节数
warnings	TEXT	章节重排、重复标题等提示 JSON
created_at	TEXT	比对创建时间

旧、新版本编号须不同。应用层同时校验所属药品相同、旧版日期不晚于新版。任务总差异数、待复核数和完成状态由其差异记录汇总计算，未单独保存易失配的统计字段。

4.4 差异与审核表 changes

字段	类型	含义与约束
id	INTEGER	主键

字段	类型	含义与约束
comparison_id	INTEGER	所属比对，外键指向 comparisons.id
payload	TEXT	章节差异内容 JSON
status	TEXT	pending、confirmed 或 ignored，默认 pending
note	TEXT	审核意见，默认空串
reviewer	TEXT	本地审核员显示名称，默认空串
reviewed_at	TEXT	最近一次审核时间，未审核时可为空
revision	INTEGER	更新修订号，默认 0

payload 保存章节键、章节名称、变化类别、关注级别、旧文、新文、两侧位置、差异片段和标记。status 使用数据库 CHECK 约束限制取值。审核信息单独保存，使原始比对结果与后续处理意见相互区分。

4.5 操作记录表 audit 与设置表 settings

表	字段	类型	含义
audit	id	INTEGER	主键
audit	action	TEXT	操作名称
audit	entity_type	TEXT	逻辑关联对象类型
audit	entity_id	INTEGER	逻辑关联对象编号
audit	detail	TEXT	操作详情，通常为 JSON
audit	actor	TEXT	本地操作者显示名称
audit	created_at	TEXT	记录时间
settings	key	TEXT	设置键，主键
settings	value	TEXT	设置值，非空

audit 的 entity_type 和 entity_id 构成应用层关联，不是指向 changes 或其他业务表的数据库外键。settings 的 demo 键保存演示药品与比对编号，避免重复加载生成重复示例。系统为版本所属药品、差异所属比对、比对版本组合建立索引。

5. 文件导入与原始资料保存

导入流程依次执行档案存在性检查、元信息验证、文件读取、格式解析、正文长度校验、章节识别、附件保存、数据库写入及操作记录写入。文本粘贴入口将文本编码为 UTF-8，以 pasted-text.txt 形式进入相同处理链。

文件名先清理路径分隔符并取末级文件名；内部文件名采用 UUID 加扩展名，防止上传名称覆盖其他附件。SHA-256 根据原始上传字节计算。提取文本与人工整理章节分开保存：校正章节不改变文件内容、摘要和原始提取文本。摘要只用于核对内容，不证明文件发布者身份或官方核准状态。

数据库写入失败时回滚事务，并清理该操作新建的附件。文件系统与数据库并非同一种事务资源，正常异常路径可清理新文件，突然断电等情况仍需通过备份和人工核对恢复。V1.0 未提供版本原件覆盖或删除接口。

5.1 各格式提取策略

TXT 依次尝试 utf-8-sig、GB18030 解码，统一换行、去除 BOM，拒绝空文本和空字符。PDF 检查文件标识、加密状态、页数及图片资源后提取文字。为避免“扫描正文加可提取页码”被误认为完整文字，任何检测到的图片均拒绝，包括嵌套 Form、内联图像、图案及批注外观资源中的图片。纯文字 PDF 的各页文字按顺序连接。

DOCX 先检查 ZIP 包规模、压缩比、加密标记及主文档结构。程序按页眉、正文、页脚顺序读取段落，保留表格和文本框内的文字，并避免重复读取嵌套段落。带未接受修订或脚注、尾注的文档拒绝导入。程序不识别 DOCX 图片中的文字，也不保证复原复杂版式，使用者应在导入后核对原件。

5.2 主要输入限制

检查位置	限制
文件入口	原始文件不超过 10 MiB
应用正文	提取或粘贴正文不超过 300,000 字符
PDF	不超过 100 页，拒绝加密和检测到图片的文档
DOCX 包	不超过 2,500 个条目；解压体积不超过 40 MiB
DOCX 压缩比	单条目超过 1 MiB 且压缩比大于 200 时拒绝
自动章节解析	不超过 500 个章节
人工章节更新接口	1 至 200 个章节；标题与正文合计不超过 300,000 字符
人工章节标题	规范化函数实际限制为 1 至 120 字符
审核意见	不超过 3,000 字符

文档底层函数另有 1,000,000 字符保护上限，但通过本应用导入时先适用更严格的 300,000 字符限制。人工校正底层函数可接受最多 500 章，而 HTTP 接口限制为 200 章；不能将底层上限当作界面可用上限。

6. 章节识别与人工校正

标题识别支持【】和 [] 括号标题；未带括号时，仅将已知标题或已知标题加冒号识别为章节，避免将任意短句误分为标题。标题规范化采用 NFKC、清理序号与空白、明确别名映射。例如“成分”与“成份”使用统一键，“适应证”与“适应症”使用统一键；未使用模糊语义合并。

前言文字作为独立章节保留，无法识别标题的文档保存为“全文”。未知括号标题也保留。重复标题按出现次数形成键，例如“成份”“成份#2”；标题原有井号先转换，防止与次数后缀冲突。每章保存正文及提取文本起止行。

人工校正重新验证标题、正文与数量，清空行号，并记录校正前后的结构。只要某版本已被任一比对引用，系统即拒绝继续修改章节并返回 409；需要更正时导入新版本，保证已有任务保留原审核依据。

7. 差异计算与关注标记

程序依据规范化标题和出现次数对齐两版章节。结果按新版章节顺序输出，再补充旧版独有章节：旧版不存在为 added，新版不存在为 removed，两侧均存在但规范化正文不同为 modified。仅章节顺序改变时记录提示，不作为正文变化。

正文比较将连续空白折叠为一个空格并去除首尾空白，再去除中文字符之间的空格。此过程不会把数字间空格直接删除，例如“1 0 mg”不会等同于“10 mg”。原文仍完整保存供展示，规范化仅用于判定是否产生正文变化。

对变化章节使用 SequenceMatcher 生成 equal、delete、insert 片段。替换表现为删除旧片段并插入新片段；删除侧与相同片段可重建旧文，插入侧与相同片段可重建新文。旧、新章节正文长度合计超过 30,000 字符时，采用整段删除加整段插入，并提示人工对照，限制细粒度匹配消耗。

用法用量、禁忌、不良反应、注意事项、特殊人群等配置章节出现变化时标为重点关注。数字或比例序列不同、单位及剂型计量词序列不同，也生成相应标记。数字规则允许中文紧邻数字；该规则只核对字符序列，不进行剂量换算、同义医学判断或风险评分。

重复标题按顺序配对时给出提示，避免用户将自动对应理解为语义认证。自动提取和章节规则不能保证识别全部现实说明书结构，故界面保留原文、来源与人工校正入口。

8. 审核状态与事务一致性

变化初始状态为 pending。使用者可确认、忽略或恢复待复核。ignored 必须填写非空原因；confirmed 可附审核说明。每次保存都记录本地审核员名称、时间和意见，并将 revision 加一。恢复待复核也记录为一次操作，不删除此前日志。

客户端提交当前 revision；服务端读取数据库修订号，不一致时返回 409，提示刷新。写入使用 BEGIN IMMEDIATE 事务，完成状态更新和操作记录写入后一起提交，失败则一起回滚。连接开启外键检查与 WAL 模式，锁等待超时为 15 秒。

待复核差异数量为零时，任务状态为 completed；未检出差异的比对也可完成并导出。这表示流程中没有未处理差异，不表示说明书内容得到医学或监管认可。操作者名称来自配置，是记录标签而非经认证身份。

9. 界面与交互设计

界面以哈希路由组织工作台、药品与版本、比对与审核、操作记录。药品和比对列表在已加载数据上提供关键字筛选；审核页按状态及关注级别筛选。差异左右并列显示，并使用删除、新增样式区分变化，数字与计量文本可进一步突出。

所有用户文本在 HTML 插入前转义。行内差异渲染前验证片段能准确重建该侧原文，无法重建时回退到原文展示。异步路由使用请求代次避免旧响应覆盖新页面；弹窗打开后同步设置初始焦点，避免延迟聚焦干扰快速填写。表单包含必填项、长度限制、忙碌状态和错误提示。

10. HTTP 接口设计

一般请求与响应使用 JSON；文件上传使用 multipart/form-data；文件和报告下载使用附件响应。服务端校验输入模型并拒绝未声明字段。业务异常使用包含 detail 的 JSON 错误信息。

方法	路径	主要用途
GET	/api/health	运行状态、版本、模式和审核员标签
GET	/api/dashboard	档案、版本、比对、待复核统计及最近操作
GET	/api/drugs	药品列表及版本数量
POST	/api/drugs	新建药品档案
GET	/api/drugs/{id}	药品详情
GET	/api/drugs/{id}/versions	指定药品的版本列表
POST	/api/drugs/{id}/versions	上传说明书文件
POST	/api/drugs/{id}/versions/text	保存粘贴文本版本
GET	/api/versions/{id}	版本、原文及章节详情
GET	/api/versions/{id}/file	下载原始文件
PUT	/api/versions/{id}/sections	更新尚未参与比对的章节
GET	/api/comparisons	比对任务列表
POST	/api/comparisons	建立新旧版本比对
GET	/api/comparisons/{id}	比对详情与审核信息
PATCH	/api/changes/{id}	更新差异审核状态及意见
GET	/api/comparisons/{id}/export	按 format 参数导出 html、csv、json
GET	/api/audit	返回最近 500 条操作记录
POST	/api/demo	幂等加载模拟示例

404 表示记录或文件不存在；409 表示已引用章节不可改或审核修订冲突；413 表示请求或文件过大；422 表示输入、文件解析或业务配对条件不符合要求。主机和来源检查可返回 400、403。

11. 报告设计

导出时读取当前任务、两份版本和各条审核信息，记录导出时间。HTML 报告包含统计、来源、文件名、SHA-256、旧新正文、定位、差异及审核意见，可独立打开并通过浏览器打印为 PDF。软件不直接调用 PDF 生成服务。

CSV 使用 UTF-8 BOM 编码，包含版本来源、摘要、变化类型、两侧文本、标记及审核信息。对以公式符号开头或可能隐藏公式前缀的内容添加文本前缀，减少表格程序解释为公式的风险。JSON 保留完整结构化内容并追加 exported_at，供程序读取。

HTML 文本进行字符转义；导出文件名只保留安全 ASCII 字符，报告设置限制性内容安全策略。报告反映导出时点状态，后续审核变化不会修改已经下载的文件。

12. 配置、访问保护与恢复

run.py 默认监听 127.0.0.1:8000，数据目录默认位于项目目录的 data。直接启动应用时，MEDLABEL_DATA_DIR 指定数据位置；MEDLABEL_REVIEWER 设置审核员显示名称；MEDLABEL_ALLOWED_HOSTS 可追加主机名。

默认主机限制为 localhost、127.0.0.1、::1。写请求要求 X-Requested-With: MedLabelReview；请求含 Origin 时校验协议、主机和端口一致，不开放跨域接口。响应添加防 MIME 嗅探、禁止页面嵌入和不缓存等头部。上述检查用于本地应用访问保护，并不提供用户登录或访问权限分配。

附件下载先校验解析后的路径仍位于 uploads 目录。SQL 值采用参数绑定；允许动态拼接的表名来自内部白名单。日志与原始附件不纳入 Git 仓库。备份应停止服务后完整复制数据库和附件目录；恢复时保持两者对应。当前操作日志可被具备本机管理权限的人修改，不是不可篡改的审计链。

13. 验证与维护

对应版本已通过 51 项自动化测试，覆盖解析边界、章节对齐、数字单位变化、来源保存、审核冲突、导出处理及主要接口。GitHub 验证在 Python 3.11、3.12 下通过，并通过真实浏览器执行的演示、审核、上传 TXT/DOCX、章节校正、比对、下载及移动端流程；弹窗焦点另有回归检查。验证记录对应提交 98e406f，不将测试样例通过扩展为全部现实文件均可正确处理。

维护时应同步更新界面、源程序、操作说明和设计文档。修改解析规则、标题别名或差异算法前，应分析对新比对结果的影响；既有比对的 payload 和审核记录不应无提示重算。扩展到多人协作、联网部署或正式业务验证时，应另行设计账户权限、数据迁移和运行控制，而不能仅修改本版的监听地址。