药品说明书版本比对与变更审核系统 V1.0

软件设计说明书

著作权人：待申请人填写

对应代码版本：98e406f；文档状态：技术内容已编制，申请信息待确认

文档项目	内容
软件全称	药品说明书版本比对与变更审核系统
软件版本	V1.0；程序内部版本标识为 1.0.0
英文项目名	MedLabel Review
对应程序版本	98e406f93f8777fc416014cee05d1737966fab4e
著作权人	待申请人填写
文档用途	说明软件的应用背景、处理问题、设计依据、内部结构和实际实现

本文描述上述代码版本已经实现的功能。示例药品、说明书文字、数值及审核意见均为虚构的软件演示资料。本文所称“审核”是使用者对文本差异进行确认、忽略及记录的操作，不是药品审评审批。

1. 应用背景与待解决问题

药学资料整理时，同一药品可能保留多个日期的说明书文件。使用者需要确定本次比较的是哪两份资料，找出章节及文字变化，再将核对意见与具体变化对应保存。文件格式、标题写法、章节顺序和排版换行可能不同；直接从文档开头逐行比较，容易把结构差异与内容差异混在一起。

以本项目的模拟资料为例，旧、新版都含“用法用量”，其中数值从 10 mg 改为 15 mg；新版另有新增“注意事项”和删除“包装”的变化。使用者除了看见文字改变，还需要知道变更属于哪个章节、原文件是什么、是否已处理、此前处理意见能否回查。这里只用虚构字段说明资料处理需求，不据此评价真实药物。

本软件针对以下四个具体问题设计：

1. 版本依据分散。仅凭文件名难以同时表达药品归属、版本日期、资料来源和导入时保存的文件内容；报告与文件分开后，也不便核查其对应关系。

2. 文本变化定位不清。标题别名、章节重排和版式空白可能产生阅读干扰，而新增、删除、数字或单位变化需要保留明确的前后文。

3. 复核结果与差异脱节。把意见另记在表格或笔记中时，需要额外维护“意见对应哪次比对、哪个章节”的关系；重新比对后也可能混用旧意见。

4. 后续修改影响已有依据。若比对建立后仍能直接改变输入章节，或者旧窗口覆盖新审核意见，已导出的结果就难以解释其形成过程。

本项目的目标是把“归集版本—定位差异—人工处理—保存依据—导出记录”放在同一条可查阅的业务流程中。本文不主张现有其他软件均无法解决这些问题，也不以未经验证的效率提升比例、识别准确率或临床效果作为设计依据。

2. 使用对象、需求与设计范围

2.1 使用对象及运行假设

使用对象为开展说明书资料整理、文本核对、教学演示的人员。V1.0 按单机、单个可信操作者设计：浏览器访问本机服务，业务文件保存在本地目录。操作者负责合法取得输入资料，核查提取结果，填写版本信息，并决定如何处理差异。

同一操作者可能同时打开多个浏览器窗口，因此单人使用仍有旧窗口提交过期意见的情况。系统采用修订号检查处理这一问题，但未据此实现多人账户、权限角色或电子签名。

2.2 需求与设计决策对应

需求编号与目标	采用的设计	可观察结果与实现位置
R1：固定两版资料的归属与来源	档案下保存独立版本，保留原文件、提取原文、日期、来源和 SHA-256	版本详情可查看原文并下载原件；app/main.py 的 add_version、version_data
R2：按章节定位变化，减少结构扰动	标题规范化及明确别名映射；同名章节按出现次序配对	新增、删除、修改分别列出，重排及重复标题另作提示；parse_sections、compare_sections
R3：让使用者优先查看特定变化	固定重点章节表，比较数字和计量词序列	每项差异显示关注标记与重点/常规级别；app/comparison.py
R4：保存差异对应的人工处理意见	每个比对拥有独立差异记录；每项保存状态、意见、操作者标签、时间和修订号	可确认、忽略和恢复待复核；review_change 及 changes 表
R5：避免历史依据被后续操作覆盖	已被比对引用的章节禁止修改；审核更新检查 revision；业务与日志同事务	无效修改被拒绝，冲突返回 409；update_sections、Database.connect
R6：让结果离开程序后仍可核查	导出时同时组织来源、差异、审核状态及导出时间	HTML、CSV、JSON 均包含版本来源信息；app/reports.py

设计选择强调输入、输出和人工操作能够相互对应。SHA-256 用于核对文件内容；关注标记用于安排复核顺序；审核记录用于回查处理过程。三者均不替代对资料真实性、医学正确性或权利归属的专业判断。

2.3 功能边界

本版支持药品档案建立与查询、说明书版本导入、自动章节识别及人工校正、两版章节和字符差异、逐项审核、报告导出、操作记录查询。档案和版本未提供编辑元信息或删除接口；改变已有资料时，应根据实际情况建立新档案或导入新版本。

导入格式为 TXT、纯文字且不含图片的 PDF、DOCX，以及粘贴文本。系统不提供 OCR、文档翻译、自动医学语义判断、药品监管数据库联网核验、处方生成、多人审批或账户认证。V1.0 的规则比对不调用生成式模型；这描述软件运行方式，不表示其开发过程未使用辅助工具。

3. 业务流程及输入输出

完整业务以药品档案为起点，以可回查的差异及审核报告为输出。使用者先创建档案，再在同一档案下导入旧、新两份版本。每份版本导入成功后立即保存原件、原文和自动识别章节；使用者可以先核对章节，必要时人工调整标题和正文。创建比对前的核对属于操作建议，程序不把“已人工核对”设为单独的强制审批状态。

创建比对时，服务端检查两个版本编号不同、属于同一药品档案、旧版日期不晚于新版日期。日期相同且编号不同可以比较。通过校验后，程序生成并保存差异记录；两份版本的章节随后因被引用而不可再修改。需更正时导入新的版本，再创建新的比对任务。

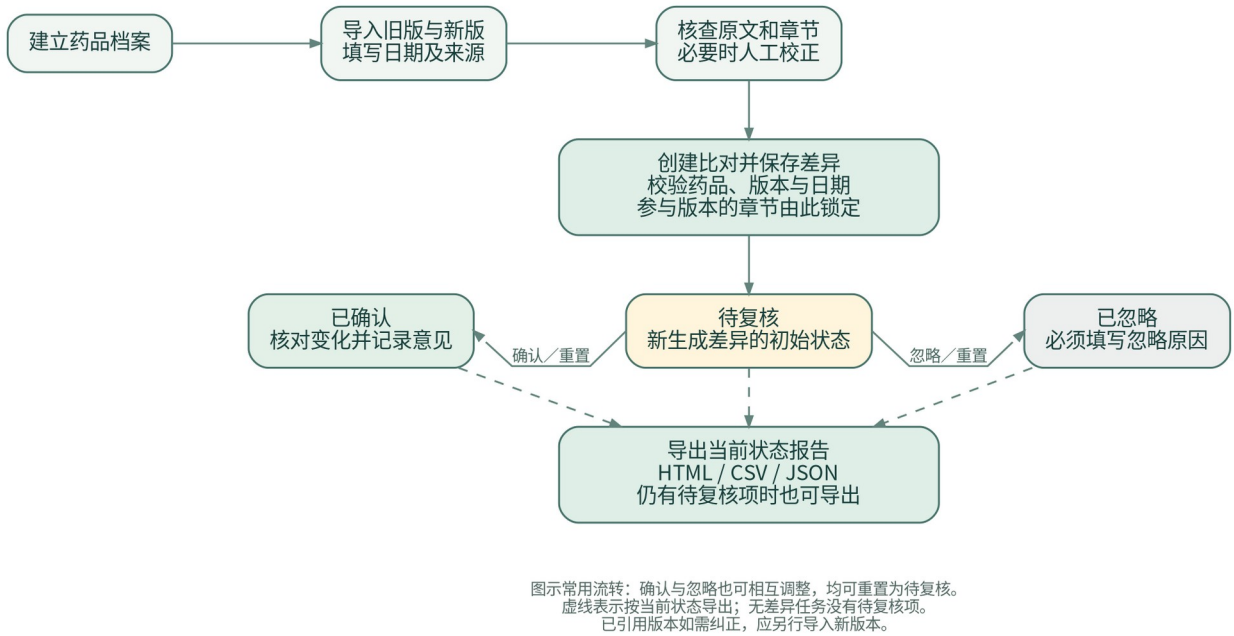


图 1 业务流程与审核状态

处理阶段	输入	处理与输出
建立档案	名称及可选厂家、规格、批准文号、备注	保存药品记录和创建日志
导入版本	档案编号、版本名称、日期、来源、文件或文本	保存附件、SHA-256、提取原文、章节和导入日志
核查章节	版本详情及原始资料	使用者确认或人工校正；校正保留原件和原文，清空不可验证的章节行号
建立比对	同一档案下两份版本编号	保存任务、变化章节、未变化章节数及提示；变更初始为待复核
人工复核	差异、目标状态、意见、当前修订号	保存审核字段及对应操作记录；返回新的修订号
导出报告	比对编号与导出格式	生成反映导出时点状态的 HTML、CSV 或 JSON

审核过程中可以随时导出，报告如实显示尚待复核的项目。全部差异处理完成后也可再次导出。后续操作不会修改已经下载的报告，重新获取当前结果需要重新导出。对同一对版本再次创建比对会形成独立任务和独立审核记录，不自动沿用旧任务的处理意见。

4. 总体架构及技术选择

4.1 架构分层

系统由浏览器界面、HTTP 业务接口、文档与比对处理模块、本地持久化组成。浏览器通过同一服务加载静态页面并调用接口；服务端先校验输入，再执行资料解析、比对、审核保存或导出。SQLite 存储结构化业务记录，uploads 保存原始文件，两者通过版本记录中的内部文件名建立联系。

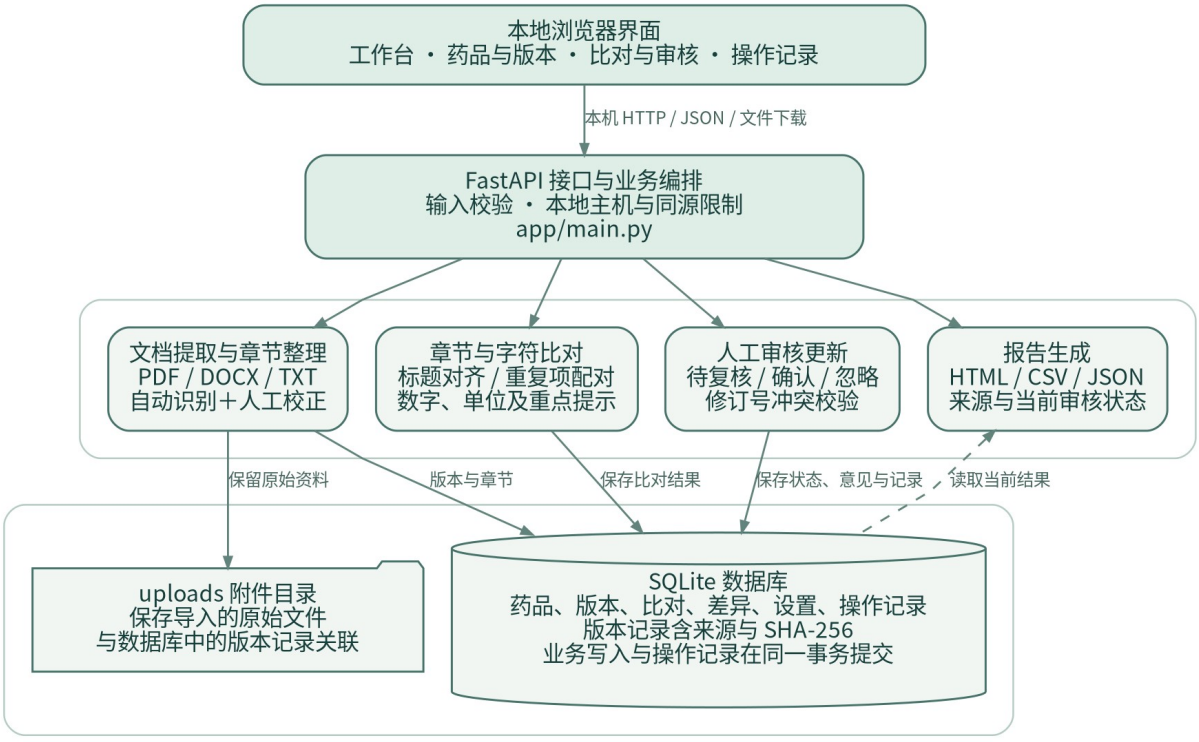


图 2 系统结构与数据存储关系

采用本地浏览器界面，便于在同一页面查看版本、原文、差异和审核意见；采用 Python 服务集中处理格式解析及规则，使浏览器不承担文件解析职责；采用 SQLite，减少单机演示对独立数据库服务的安装要求；采用原生 JavaScript 和静态样式，不要求 Node.js 构建流程。以上是本版部署范围内的取舍，不作为大规模协作或高并发系统的性能承诺。

4.2 模块职责

模块	实际源文件	主要职责及边界
启动	run.py	读取监听地址、端口、数据目录并启动 Uvicorn
业务接口	app/main.py	输入模型、档案和版本管理、配对约束、审核状态、事务调用

模块	实际源文件	主要职责及边界
持久化	app/database.py	建表、连接、外键检查、写事务、操作记录
文档处理	app/documents.py	格式提取、标题识别与规范化、章节切分、人工校正验证
比对处理	app/comparison.py	标题对齐、变化分类、字符差异、关注标记
报告	app/reports.py	组织来源和当前审核状态，输出三种格式
界面	app/static/index.html、app.js、styles.css	路由、表单、原文查看、差异显示、审核和下载
演示	app/demo.py、examples/	提供明确标注的虚构资料，便于重复验证流程

4.3 开发和运行支撑

程序以 Python 3.11 及以上版本作为运行要求，使用 FastAPI、Uvicorn、pypdf、python-docx 和 Python 标准库中的 SQLite、difflib 等组件。依赖安装完成后，本地资料处理不依赖外部网络、大模型密钥或第三方数据库服务。

归档验证覆盖 Linux 环境中的 Python 3.11、3.12 自动化测试及 Chromium 浏览器操作。项目提供 Windows PowerShell、macOS/Linux 启动方式，但不把启动脚本的存在表述为这些平台均已通过验收。具体依赖和验证版本分别记录在 requirements.txt、requirements-lock.txt 及测试验收记录中。

5. 数据组织、关联关系与不变条件

数据库文件为 medlabel.sqlite3，共六张表。drugs 对 versions 为一对多；每个 comparisons 引用一个药品以及旧、新两个版本；comparisons 对 changes 为一对多。audit 通过对象类型和编号逻辑关联操作对象；settings 保存演示初始化标记。完整字段见附录 A。

5.1 原始依据与处理结果分别保存

每个版本保留三种内容：上传文件的原始字节、格式提取后的原文、用于比较的章节结构。原件用于回查输入，原文用于检查格式提取，章节用于规范组织比较。人工校正只替换章节结构，不回写附件或提取原文，也不重新计算其 SHA-256。

章节项包括 key、title、text、start_line、end_line。title 保存用于展示的标题，key 标识规范化后的标题与出现次数，text 保存该章正文。自动识别的行号指向提取文本，包含标题所在行，不是 PDF 页码或屏幕坐标。人工校正后的行号设为空，避免将修改后的正文假装定位到原始行号。

比对建立时，差异正文、类型、位置、标记和字符片段写入 changes.payload；审核字段单独保存。比对详情读取已保存的 payload，不因用户再次打开页面而重新计算差异。既有比对引用的章节不可修改，使报告中的版本、来源和变化记录保持相互对应。

5.2 数据约束

不变条件	实现措施	对业务的作用
版本必须归属于已有药品	导入先查询档案，数据库使用外键	防止形成无所属档案的版本
比对必须引用同档案的不同版本	add_comparison 校验编号、药品和日期；数据库 CHECK 检查编号不同	防止把不同药品或反向日期当成同一次修订
比对依据固定	update_sections 检查是否被任意比对引用	更正输入时通过新版本保留旧依据
审核状态只能取定义值	输入 Literal 与数据库 CHECK	避免未知状态进入统计和报告
旧窗口不能覆盖较新审核	比较 revision，再在写事务中更新并递增	显式提示冲突，由使用者重新读取后处理
状态变更与日志同时保存	业务写入及 audit 使用同一数据库连接、事务	避免正常异常路径下出现有修改无记录

统计字段 total_changes、pending_changes 和任务状态由当前差异记录汇总，不另行保存可失配的计数。未变化章节数量在生成比对时保存，因为它属于该次比较的计算结果。日期使用 YYYY-MM-DD 文本，操作时间使用带 UTC 时区的 ISO 时间文本；对象结构以 JSON 字符串保存。

6. 文件导入、章节解析与校正设计

6.1 导入处理顺序

add_version 首先检查档案及版本元信息，再检查文件字节和扩展名，调用 extract_text 提取原文，检查应用正文长度，调用 parse_sections 生成章节。解析成功后才写入附件和版本记录，同时写入导入日志。粘贴文本转为 UTF-8 字节，以 pasted-text.txt 名称走同一保存流程。

文件名去掉路径部分后用于展示；内部文件名使用 UUID 与扩展名，避免由上传名称决定保存位置或覆盖同名附件。SHA-256 对原始字节计算，因此不同编码或文件容器的字节不同，即使可读正文相同，其摘要也可能不同。系统不使用摘要证明发布来源或自动判定两个文件语义相同。

数据库写入失败时回滚事务，并在常规异常路径清理本次新建附件。文件系统与数据库不是同一种事务资源，突然断电或强制终止仍可能需要人工核对；本版未实现跨文件系统的事务恢复协议。

6.2 格式提取策略

输入格式	提取方法	采用此策略的理由与限制
TXT	依次尝试 utf-8-sig、GB18030，统一换行并清理 BOM	支持常见文本编码；空文本、空字符及无法识别编码给出错误
PDF	校验标识、加密、页数和图片资源，再按页提取文字	防止“扫描正文＋可提取页码”造成正文遗漏；检测到图片即拒绝，含徽标的文件也可能被拒绝
DOCX	检查 ZIP 包后遍历页眉、正文、页脚中的段落与文字节点	保留表格和文本框文字；不执行图片识字，也不保证还原复杂版式
粘贴文本	按 UTF-8 保存为文本原件	与文件导入统一追溯和比对，不另设一套差异算法

PDF 图片检查覆盖页面资源、嵌套 Form、内联图像、图案和批注外观中的图片；过深或过多的图形结构也会拒绝。DOCX 对未接受的插入/删除修订以及脚注、尾注引用予以拒绝，提示先转换成完整文字；嵌套文本框段落单独读取，避免重复拼入外层段落。导入后的人工核查仍然必要，格式被接受不等于文字完整性已经得到认证。

6.3 标题识别和章节键生成

parse_sections 按提取文本行顺序处理。标题识别接受【】、[]、［］包围的标题，也接受明确别名表中的无括号标题或标题后接冒号的形式。类似 [1] 的纯数字参考编号不作为章节标题；未知的普通正文短句也不提升为标题，减少误切分。

canonical_title 对标题执行 NFKC 规范化，清理前缀序号与空白，再使用显式别名表。例如“成分”和“成份”归为同一键，“适应证”和“适应症”归为同一键。没有相应别名的标题保留自己的规范化形式，不进行模糊医学概念合并。

第一处标题之前的文字保留为“前言”；全文没有识别到标题时，保留为“全文”章节。未知括号标题和空正文标题也保留。重复标题按出现次序生成“成份”“成份#2”等键；标题原有的半角井号先转换，防止与次数后缀碰撞。原文件只有一个章节时，版本记录附带提醒使用者核查结构的提示。

6.4 人工校正及输入上限

使用者可以在尚未参与比对的版本中添加、删除或修改章节。服务端重新校验并生成键，所有校正章节的行号置空，记录校正前后结构。任何一次比对引用该版本后，继续保存校正返回 409，应重新导入版本。当前界面仍可打开章节查看窗口，是否允许保存由服务端最终判断。

检查位置	实际限制
文件字节	不超过 10 MiB
应用导入正文	不超过 300,000 字符
PDF 页数	不超过 100 页
DOCX 包	不超过 2,500 个条目，解压体积不超过 40 MiB
DOCX 压缩比	单条目超过 1 MiB 且压缩比大于 200 时拒绝
自动章节	最多 500 个
人工校正 HTTP 接口	1 至 200 个章节；标题和正文合计不超过 300,000 字符
人工章节标题	最终经 normalize_sections 检查为 1 至 120 字符
资料来源	界面要求填写且最多 1,000 字符；服务端接受空值且最多 2,000 字符
审核意见	不超过 3,000 字符

底层文档处理函数另设 1,000,000 字符保护上限，人工校正底层函数最多接受 500 章；经本应用入口时适用表中更严格限制。自动导入形成 201 至 500 章时，可以保存导入结果，但原样提交人工校正将超过接口上限，需要先整理章节或重新拆分资料。前端和 SectionInput 的标题长度上限为 200，但 normalize_sections 最终只接受 120，故本版有效标题上限按 120 说明。这里如实区分各层约束，未把底层上限写成界面能力。

7. 章节对齐、差异计算与关注规则

7.1 对齐和变化分类

compare_sections 从章节标题重新计算规范化键，不信任调用者传入的可变 key。两版以“规范化标题＋同名出现次数”建立索引，结果按新版章节顺序输出，再追加旧版独有章节。它不依赖两版相同行号或相同章节序号，因此章节重排不会直接造成整篇错位。

两侧对应关系	判定结果
仅新版存在该键	added：新增章节
仅旧版存在该键	removed：删除章节
两侧都有且规范化正文不同	modified：内容修改
两侧都有且规范化正文相同	计入 unchanged_sections，不生成待复核差异

比较前，_comparison_text 将连续空白折叠为一个空格，并删除中文字符之间的空格，减少换行排版干扰。该规范化不移除否定词、标点、小数点或数字之间的分隔空格；“1 0 mg”不会被合并成“10 mg”。完整原文仍保存在版本和差异中，规范化只用于是否生成正文变化的判定。

如果共有章节的先后顺序不同，输出重排提示；存在重复标题，输出按出现次序配对的提示；任一版本仅作为“全文”比较时，提示可在创建任务前整理章节。重复章节的次序配对不保证语义上一一对应，需使用者核对。标题改名且不在别名表内时，会呈现旧章删除和新章新增；已识别别名之间仅标题写法变化、正文相同时，不单独产生标题变化记录。

7.2 字符差异和原文重建

对已判定发生变化的章节，_inline_segments 使用 SequenceMatcher 在原始章节正文上计算字符差异，产生 equal、delete、insert 三种片段。替换由一段删除和一段插入表达。把非 insert 片段拼接应得到旧文，把非 delete 片段拼接应得到新文；这一性质用于前端显示校验及自动测试。

对两侧正文均非空的变化章节，长度合计超过 30,000 字符时，不继续细粒度匹配，改为整段旧文删除与整段新文插入，同时提示人工对照。纯新增或纯删除直接展示相应一侧全文，不追加该长章节提示。这个处理限制长输入的比较开销，未承诺所有输入都能即时完成。空新增、删除章节仍按章节存在性列入变化，不因正文为空而消失。

7.3 关注标记的确定

关注标记由三个彼此独立的条件产生：第一，规范化标题属于固定重点章节表，例如用法用量、禁忌、不良反应、注意事项、特殊人群用药、药物相互作用等；第二，正则提取的数字或比例序列在两侧不同；第三，正则提取的单位及剂型计量词序列在两侧不同。

数字提取允许中文紧邻数字，可包含正负号、小数或逗号分隔形式及百分号。单位表包括 mg、g、mL、IU、℃ 和毫克、毫升、片、粒等明确列出的词。程序比较的是按出现顺序得到的字符串列表，不执行数值换算、剂量等价判断或语义理解；日期数字、数字格式或单位字母大小写变化也可能触发提示。未被表和正则覆盖的表述可能没有专门标记，但已识别的正文变化仍会显示。

重点章节或数字、单位序列变化使 priority 为 high，其他为 normal。长章节整段展示提示本身不必然使优先级升高。界面中的“重点复核”和报告中的“重点关注”对应同一个 high 值，表示阅读顺序，不表示医学风险高低。未变化的重点章节不会因为名称在表内而被额外列为变化。

8. 审核状态和一致性设计

8.1 单项状态与任务汇总

每项差异创建时为 pending（待复核），revision 为 0。使用者可以将其保存为 confirmed（已确认）或 ignored（已忽略），也可以把已处理项目恢复为 pending。所有合法状态之间均可重新保存，不存在最终签署后不可撤销的审批阶段。

操作	保存条件	保存后的效果
确认变更	提交当前 revision；意见可为空	状态为 confirmed，保存意见及时间
忽略变更	提交当前 revision，必须填写非空原因	状态为 ignored，保存忽略原因及时间
恢复待复核	提交当前 revision	状态为 pending，保留本次操作记录；任务可能重新出现待复核项
修改已确认意见	提交当前 revision	保存新意见并递增 revision，旧意见可由日志回查

每次成功保存均写入操作者显示名、操作时间、意见，并使 revision 加一。相同状态的再次保存也属于一次更新。任务有待复核项目时为 pending；待复核数为零时为 completed。没有检出变化的任务也为 completed。完成度为已处理项数与变化项总数的关系，不是软件对说明书正确性的评分。

8.2 修订冲突与原子更新

浏览器读取差异时获得 revision，提交审核时连同目标状态和意见发送。服务端在 BEGIN IMMEDIATE 写事务中读取最新记录；若修订号不同，返回 409，不覆盖已有意见。相同时，更新状态并递增修订号，再把更新前后的状态、意见和新修订号写入 audit，最后一起提交。异常时一起回滚。

例如同一差异 revision 为 0，窗口甲确认后变为 1。窗口乙仍用 0 提交忽略，服务端拒绝。前端收到 409 后重新读取任务状态并保留当前意见草稿，乙需结合最新记录判断是否继续提交，不能把“最后一次请求到达”作为覆盖原则。连接启用外键和 WAL 模式，SQLite 锁等待超时为 15 秒。该机制服务于本地数据一致性，不提供账户身份验证。

9. 界面组织与报告输出

9.1 界面组织

界面通过哈希路由组织工作台、药品与版本、比对与审核、操作记录四个工作区。工作台汇总档案、版本、比对和待复核数量；档案详情集中显示该药品的版本；审核页左右并列旧、新正文，并附章节位置、变化类型、关注标记及处理控件。

药品、比对和日志列表在当前已加载记录上提供关键字筛选。审核页同时按单项状态和优先级筛选；筛选只影响当前显示，不改变保存的差异。操作记录接口返回最近 500 条，工作台显示最近 8 条，未实现完整日志分页检索。

所有用户文本插入 HTML 前进行转义。行内片段只有能准确重建该侧正文时才用于着色，否则显示原文。异步路由使用请求代次防止旧响应覆盖新页面；弹窗打开时同步设置初始焦点，避免延迟焦点打断快速填写。表单提供必填、长度、忙碌状态和错误提示。

9.2 报告组织

导出读取当前任务、两份版本和所有差异审核状态，并记录导出时间。三种格式均包含版本名称、日期、资料来源、文件名和 SHA-256，以及差异的旧新正文、位置、类型、关注标记、状态、意见、操作者标签、复核时间和修订号。HTML 和 JSON 另保留版本导入时间；CSV 未设置导入时间列。使用者可依据报告中的任务编号和章节信息核对对应记录与原文件，HTML 和 CSV 不提供独立差异编号或返回程序的跳转链接。

格式	主要用途	实现方式
HTML	独立阅读、查看逐字差异和打印	页面内置样式及来源信息；可用浏览器打印为 PDF
CSV	在表格软件中整理和筛选	UTF-8 BOM 编码；以差异为行，重复附带版本来源字段
JSON	保存完整结构或由其他程序读取	保留任务、版本、变化、审核字段，追加导出时间

HTML 逐字差异对用户文本转义；报告设置限制性内容安全策略。CSV 对以公式符号开头或经空白隐藏公式前缀的单元格添加文本前缀，减少表格程序解释为公式的风险。下载文件名采用安全 ASCII 字符。系统不直接生成 PDF 文件，不为报告赋予电子签名或监管结论效力。

10. 可重复的模拟业务示例

10.1 输入及前置条件

使用仓库中的 examples/demo-v1.txt 和 examples/demo-v2.txt，或首次载入内置演示数据；两者为同一组虚构文字。下面按两份 TXT 的未经人工校正的章节结果说明，其他文件格式可能因提取换行不同导致行号不同。

建立“示例药品 A（模拟）”档案，将旧版名称填为“模拟初始版”、日期 2026-01-01，新版名称填为“模拟修订版”、日期 2026-06-01，来源注明项目内置虚构示例。分别导入后，两版均为 11 个章节，包含前言。核对原文完整后，选择两版创建比对。

10.2 预期差异与规则解释

章节	输入中的变化	结果与依据
用法用量	虚构测试数值 10 mg 改为 15 mg	modified、重点；命中重点章节及数字变化，mg 未变化，不产生单位变化标记
禁忌	新增“不得替代药师审核”的模拟规则	modified、重点；命中重点章节
不良反应	将待补充演示字段改为新增虚构字段	modified、重点；命中重点章节
注意事项	新版新增人工核对提示	added、重点；旧版显示无对应章节
说明书修订日期	2026-01-01 改为 2026-06-01	modified、重点；数字序列变化，不能理解为日期变更具有医学风险
包装	新版删除模拟包装 A	removed、常规；新版显示无对应章节

结果共有 6 项变化，其中 4 项修改、1 项新增、1 项删除；另有 6 个章节内容一致。两版各有 11 章，而其章节键的并集为 12，因此“6 项变化＋6 项一致”与输入章节数并不矛盾。结果含 5 项重点和 1 项常规，未产生重排、重复标题或全文比较提示。TXT 样例的用法用量定位为两侧提取文本第 10—11 行；注意事项的新侧为第 16—17 行。

10.3 人工复核、恢复与导出

新建任务的 6 项均待复核。确认“用法用量”并填写“已与模拟原文核对，仅记录数值变化”后，该项 revision 从 0 变为 1，任务待复核数从 6 变为 5。将“包装”标为忽略时填写“模拟示例仅用于演示删除章节处理”，状态成为 ignored；这不表示程序自动认为删除无需关注。

其余 4 项逐一确认后，6 项均已处理，任务状态为 completed。此时导出报告包含 5 项已确认、1 项已忽略及双方来源信息。再将任一已确认项恢复待复核，任务待复核数变为 1；之前导出的文件保持原内容，新导出文件体现新的状态和导出时间。

这个示例分别展示了版本归集、增删改分类、标记依据、人工意见、状态汇总和报告时点的对应关系。实际审核可以选择其他处理结论；软件不依据本示例预先替用户作出医学判断。

11. 异常处理、访问保护与维护

11.1 主要异常及恢复方式

场景	程序行为	使用者处理
空文件、损坏文件或不支持格式	拒绝导入，返回可读错误；不生成成功版本记录	重新导出为支持格式后导入
含图片 PDF、DOCX 未接受修订或脚注尾注	拒绝并提示可能遗漏内容	在外部工具转换为完整文字并人工核查
请求或文件过大	返回 413，或在正文等业务校验时返回 422	拆分为单份、合适规模资料
同版本、跨档案或反向日期比较	返回 422，不创建任务	重新选择正确配对
已引用版本继续校正	返回 409	导入更正后的新版本并新建任务
旧窗口提交审核	返回 409，界面重新读取状态并保留草稿	核对最新意见与当前草稿后再保存
记录或原附件不存在	返回 404	核对数据目录、记录及备份，不伪造缺失原文
忽略未写原因	返回 422	补充实际原因后保存

输入验证错误统一返回含 detail 的 JSON，前端显示对应信息。业务错误不转成看似成功的空结果。系统无登录恢复、账号审批或自动医学纠错流程。

11.2 本地访问保护

run.py 默认监听 127.0.0.1:8000。服务默认允许 localhost、127.0.0.1、::1 主机名；写请求要求 X-Requested-With: MedLabelReview，并在存在 Origin 时校验协议、主机和端口一致。错误主机或来源可返回 400、403。响应添加防 MIME 嗅探、禁止页面嵌入和不缓存等头部。

数据库值使用参数绑定，动态表名来自内部白名单。附件下载验证解析后的路径仍位于 uploads 目录。上述措施降低本地使用中恶意文本、路径及跨来源写入的风险，不等同于多用户访问控制；具备本机文件权限的人仍可读取或修改数据库、附件和日志。

11.3 配置、备份与版本维护

启动参数 --data-dir 指定保存目录，默认是项目目录下的 data；直接启动应用时可用 MEDLABEL_DATA_DIR。MEDLABEL_REVIEWER 设置本地记录标签，MEDLABEL_ALLOWED_HOSTS 可增加允许的主机名，但不会自动增加登录认证。

备份前停止服务，完整复制数据目录，包含数据库、附件及目录中存在的数据库相关文件。恢复时保持数据库与附件对应，再以该目录启动。V1.0 采用手工目录备份，没有自动备份调度、异地灾备或不可篡改审计链。

修改章节别名、解析和差异规则时，需要重新验证新版本的结果并同步更新文档；已有任务的差异快照不应无提示地重新生成。若未来扩展为多人联网使用，需另行设计身份认证、角色授权、部署安全及迁移策略，不能把本版的本地配置说明当作已实现这些能力。

12. 验证依据及结论范围

程序基线的既有验收记录为 51 项自动化测试通过，GitHub 验证涵盖 Python 3.11、3.12；Chromium 浏览器流程覆盖演示、审核、新建档案、TXT/DOCX 导入、章节校正、比对、导出及移动端访问。记录见 docs/测试与验收记录.md。本文修订对第 10 章两份 TXT 调用实际提取、解析与比较函数复核了章节数、变化类型和标记；这不是新增临床或外部监管验证。

需求与关键行为	既有验证依据	验证所支持的结论
R1 原件及来源保留	test_uploaded_original_hash_and_filename_are_preserved_safely	文件名清理、摘要和原文下载对应原上传内容
R2 标题对齐、重复及重排	test_align_by_heading_not_order_and_aliases；test_repeated_headings_are_retained_and_warning_is_explicit	别名与顺序变化按既定规则处理，重复标题有提示
R3 数字、单位和否定词变化	test_negation_number_and_unit_changes_never_normalized_away；test_numeric_token_spaces_not_removed	所选样例变化未被空白规范化消除
R4 审核状态和意见	test_complete_review_lifecycle_preserves_audit	确认、忽略校验、恢复及历史意见记录可对应
R5 输入锁定与冲突	test_section_correction_locks_after_comparison；同上审核生命周期测试	已引用章节不可变，过期修订被拒绝
R6 报告及无变化任务	test_exports_escape_user_content_and_neutralize_formulas；test_empty_diff_is_complete_and_exports_valid_csv	来源保留、HTML 转义、CSV 防公式及空差异导出
输入格式边界	tests/test_documents.py 中 PDF、DOCX、编码及人工校正测试	所选损坏、图片、修订及结构样例按预期处理

需求与关键行为	既有验证依据	验证所支持的结论
界面完整业务	scripts/browser_smoke.py 及验收记录	指定桌面和移动端流程能够完成；弹窗焦点另有回归核查

验证范围是选定输入与操作路径，不推广为所有现实药品说明书都能无遗漏解析。识别别名覆盖度、复杂版式、单位词表、重复标题语义对应和本地权限是需要人工核查或后续扩展的边界。本文不提供性能数值、医学准确率、法规认证或登记结果保证。

附录 A. 数据库字段

A.1 drugs：药品档案

字段	类型	含义与约束
id	INTEGER	主键
name	TEXT	名称，非空
manufacturer	TEXT	厂家，非空，默认空串
specification	TEXT	规格，非空，默认空串
approval_number	TEXT	批准文号，非空，默认空串
notes	TEXT	备注，非空，默认空串
created_at	TEXT	建立时间，非空

档案用于资料归集，名称和批准文号不经过外部监管数据库认证。

A.2 versions：说明书版本

字段	类型	含义与约束
id	INTEGER	主键
drug_id	INTEGER	非空，外键指向 drugs.id
label	TEXT	版本名称，非空
version_date	TEXT	版本日期，非空
source	TEXT	来源描述，非空，默认空串
filename	TEXT	清理路径后的原文件名，非空
sha256	TEXT	原始字节摘要，非空
storage_name	TEXT	UUID 内部附件名，非空；不在版本接口公开
text	TEXT	提取原文，非空
sections	TEXT	章节列表 JSON，非空
warnings	TEXT	提示列表 JSON，非空，默认 []
created_at	TEXT	导入时间，非空

A.3 comparisons：比对任务

字段	类型	含义与约束
id	INTEGER	主键
drug_id	INTEGER	非空，外键指向 drugs.id
old_version_id	INTEGER	非空，外键指向 versions.id
new_version_id	INTEGER	非空，外键指向 versions.id；须与旧编号不同
unchanged_sections	INTEGER	未变化章节数，非空
warnings	TEXT	比对提示 JSON，非空，默认 []
created_at	TEXT	创建时间，非空

A.4 changes：差异和当前审核信息

字段	类型	含义与约束
id	INTEGER	主键
comparison_id	INTEGER	非空，外键指向 comparisons.id
payload	TEXT	差异快照 JSON，非空
status	TEXT	非空，默认 pending；CHECK 限定 pending、confirmed、ignored
note	TEXT	审核意见，非空，默认空串
reviewer	TEXT	本地记录标签，非空，默认空串
reviewed_at	TEXT	最近审核时间，初始可为空
revision	INTEGER	非空，默认 0，保存审核时递增

payload 包含 section_key、section_title、kind、priority、old_text、new_text、old_location、new_location、segments、flags。状态和意见单独存储，不改写既有差异快照。

A.5 audit：操作记录；settings：本地设置

表	字段	类型	含义与约束
audit	id	INTEGER	主键
audit	action	TEXT	操作名称，非空
audit	entity_type	TEXT	逻辑关联对象类型，非空
audit	entity_id	INTEGER	逻辑关联对象编号，非空
audit	detail	TEXT	详情，通常为 JSON，非空
audit	actor	TEXT	操作者标签，非空
audit	created_at	TEXT	时间，非空
settings	key	TEXT	设置键，主键

表	字段	类型	含义与约束
settings	value	TEXT	设置值，非空

audit 的对象类型和编号不是指向某一业务表的数据库外键。settings 的 demo 键保存演示药品和比对编号，使重复加载返回同一示例。数据库为 versions.drug_id、changes.comparison_id 及 comparisons 的旧新版组合建立索引；这些索引不限制同一版本组合只能创建一次任务。

附录 B. HTTP 业务接口

一般请求和响应使用 JSON，上传使用 multipart/form-data，原件和报告以附件返回。Pydantic 输入模型拒绝未声明字段；上传入口的表单字段另由路由及业务函数校验。以下列出 18 个业务接口，页面及静态资源路由另行提供界面文件。

方法	路径	用途
GET	/api/health	状态、版本、模式及审核员标签
GET	/api/dashboard	汇总数量和最近 8 条操作
GET	/api/drugs	药品及其版本数量列表
POST	/api/drugs	建立档案
GET	/api/drugs/{id}	档案详情
GET	/api/drugs/{id}/versions	档案下版本列表
POST	/api/drugs/{id}/versions	上传文件版本
POST	/api/drugs/{id}/versions/text	保存粘贴文本版本
GET	/api/versions/{id}	版本、原文和章节详情
GET	/api/versions/{id}/file	下载原件
PUT	/api/versions/{id}/sections	保存尚未被比对引用的章节校正
GET	/api/comparisons	比对任务列表
POST	/api/comparisons	创建独立比对任务
GET	/api/comparisons/{id}	差异、审核信息和来源详情
PATCH	/api/changes/{id}	校验修订号并保存审核
GET	/api/comparisons/{id}/export	通过 format=html、csv 或 json 导出当前状态
GET	/api/audit	最近 500 条操作
POST	/api/demo	幂等建立或返回虚构演示数据

创建档案、导入版本和创建比对成功返回 201；查询、更新及导出正常返回 200。404 为记录或文件不存在，409 为章节锁定或审核冲突，413 为请求或文件过大，422 为输入、解析或配对条件不符合要求；访问保护可返回 400 或 403。